	BoW	TF-IDF	Word2Vec	BERT
Clusterização + PCA e visualização	x	x	x	x
Busca e recomendação	x	x	x	x
Classificação	x	x	x	x

Análise de sentimentos	(x) Realizada ( ) Não realizada
Reconhecimento de Entidades Nomeadas	(x) Realizada ( ) Não realizada
Extração de Relações	(x) Realizada ( ) Não realizada

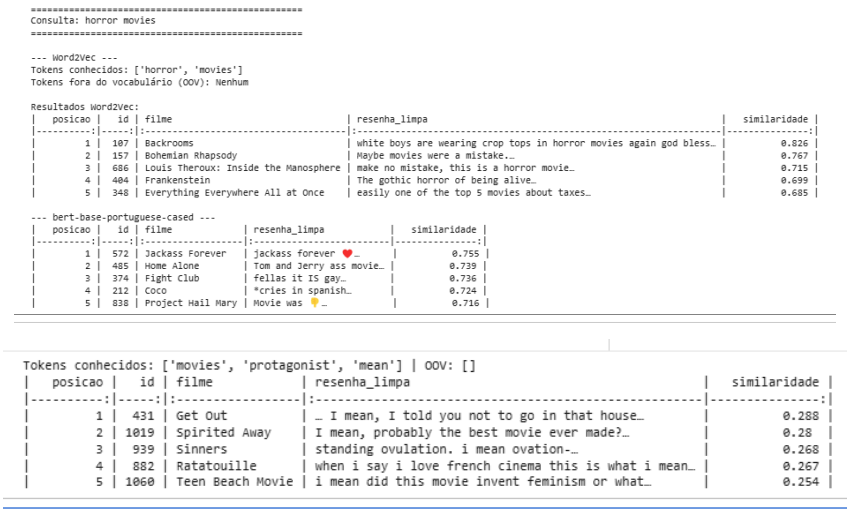
2) A distribuição dos dados dos clusters foram: cluster 0 = 1.026 resenhas; cluster 1 = 193; cluster 2 = 28; cluster 3 = 135. O forte desequilíbrio mostra que o algoritmo concentra a maior parte das resenhas em um grupo amplo e separa alguns subconjuntos menores.

	cluster	n_documentos	coesao_media	resenha_limpa
2	2	28	0.139562	the dude screaming "fuck it i'm gay" while his...
1	1	193	0.034672	It's not one take., this movie is actually ver...
3	3	135	0.032557	this is the best high school film bc it includ...
0	0	1026	0.003825	the moral of the story is that all men are evi...



O cluster 2 tem a maior coesão (0,1396), mas reúne somente 28 resenhas. Os clusters 1 e 3 têm coesões baixas (0,0347 e 0,0326), enquanto o cluster 0, que contém cerca de 70% da base, tem coesão muito baixa (0,0038). Os termos mais frequentes dos grupos grandes são genéricos (“like”, “love”, “movie”, “best”, “time”), o que limita a interpretação temática.

3) A base de dados por se tratar de variáveis com textos informais e muitos deles sendo textos curtos, os resultados das consultas nem sempre são positivos e claros com o que foi pedido.



```
==================================================
Consulta: horror movies
==================================================

--- Word2Vec ---
Tokens conhecidos: ['horror', 'movies']
Tokens fora do vocabulário (OOV): Nenhum

Resultados Word2Vec:
|   posicao |   id | filme                                 | resenha_limpa                                                          |   similaridade |
|----------:|-----:|:--------------------------------------|:-----------------------------------------------------------------------|---------------:|
|         1 |  107 | Backrooms                             | white boys are wearing crop tops in horror movies again god bless…     |          0.826 |
|         2 |  157 | Bohemian Rhapsody                     | Maybe movies were a mistake.…                                          |          0.767 |
|         3 |  686 | Louis Theroux: Inside the Manosphere  | make no mistake, this is a horror movie…                               |          0.715 |
|         4 |  404 | Frankenstein                          | The gothic horror of being alive…                                      |          0.699 |
|         5 |  348 | Everything Everywhere All at Once     | easily one of the top 5 movies about taxes…                            |          0.685 |

--- bert-base-portuguese-cased ---
|   posicao |   id | filme            | resenha_limpa            |   similaridade |
|----------:|-----:|:-----------------|:-------------------------|---------------:|
|         1 |  572 | Jackass Forever  | jackass forever ❤️…      |          0.755 |
|         2 |  485 | Home Alone       | Tom and Jerry ass movie… |          0.739 |
|         3 |  374 | Fight Club       | fellas it IS gay…        |          0.736 |
|         4 |  212 | Coco             | *cries in spanish…       |          0.724 |
|         5 |  838 | Project Hail Mary | Movie was 👎…            |          0.716 |
```



```
Tokens conhecidos: ['movies', 'protagonist', 'mean'] | OOV: []
|   posicao |   id | filme            | resenha_limpa                                                          |   similaridade |
|----------:|-----:|:-----------------|:-----------------------------------------------------------------------|---------------:|
|         1 |  431 | Get Out          | … I mean, I told you not to go in that house…                          |          0.288 |
|         2 | 1019 | Spirited Away    | I mean, probably the best movie ever made?…                            |          0.28  |
|         3 |  939 | Sinners          | standing ovulation. i mean ovation-…                                   |          0.268 |
|         4 |  882 | Ratatouille      | when i say i love french cinema this is what i mean…                   |          0.267 |
|         5 | 1060 | Teen Beach Movie | i mean did this movie invent feminism or what…                         |          0.254 |
```

A busca foi realizada em Word2vec, BERT e TFIDF. As duas primeiras consultas foram utilizando “horror movies” como entrada e a última consulta foi buscando por filmes onde a protagonista era malvada, inclusive o token “mean” que era para ser considerada uma característica o algoritmo entendeu como “I mean” . Como a consulta se baseia totalmente na resenha do usuário o resultado não é 100%, então, além de utilizar a resenha também adicionar os gêneros e sinopse do filme como parâmetros, poderia ajudar a retornar um resultado melhor.

4) Foi sim possível conseguir treinar um classificador com base nas resenhas extraídas, porém o desempenho foi baixo. A base de dados é muito desbalanceada, com cerca de 39% de notas 5,0, e as resenhas são curtas e informais. O classificador ajuda a analisar a resenha do usuário e atribuir uma nota prevista e depois compara com a nota real dada pelo usuário.



	texto	real	previsto	distancia
385	Move over, Triumph of the Will. We've got a fr...	0.5	4.063370	3.563370
735	bad haircut	0.5	3.923125	3.423125
386	This is like, some kind of weird, conservative...	1.0	3.990322	2.990322
176	I don't get the hype that this movie gets.	1.0	3.967646	2.967646
158	"I don't have time to be their cautionary tale."	1.0	3.870067	2.870067
161	Everything you need to know about "Bohemian Rh...	1.5	4.002439	2.502439
594	the only political statement this film makes i...	1.5	3.926293	2.426293
1359	i'm gonna jump from a wuthering height	1.5	3.752375	2.252375
591	I have this whole series of YouTube videos tha...	2.0	4.055504	2.055504
1361	WHY IS THERE PONY PLAY IN WUTHERING HEIGHTS WH...	2.0	4.005053	2.005053
1279	Maybe it's because when you're Jewish you tend...	2.0	3.963237	1.963237
263	straight people are so wild that purpled haire...	2.0	3.942854	1.942854
589	bad because -he never said joker's trick-super...	2.0	3.792858	1.792858
1363	I'm not a purist about adaptations. Change thi...	2.0	3.736438	1.736438
967	This review is a critical look at Sound of Met...	2.5	4.078693	1.578693

5) A análise de sentimentos é aplicável já que as resenhas expressam reações pessoais do usuário. Reconhecimento de entidades nomeadas também é possível, mas o modelo pode confundir títulos de filmes com entidades de outras categorias, perder nomes escritos em minúsculas e interpretar palavras em caixa alta como organizações, como ocorreu em alguns testes do código. Para extrair nomes de pessoas ele é eficiente, porém, os nomes precisam estar com a primeira inicial maiuscula. O EVER (palavra toda em maiusculo) que considerou como ORG é referente a uma associação europeia, quando a palavra é "ever"

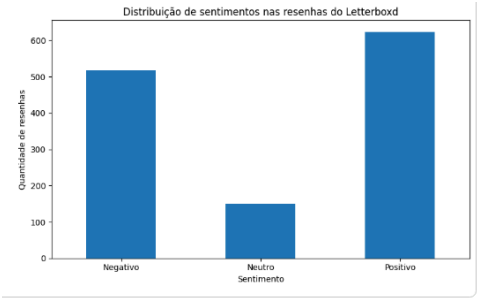
ele não considera a categoria correta do filme Call Me By Your Name seria WORK_OF_ART. A extração de relações foi realizada, mas, seus resultados não são tão bons já que em uma resenha normalmente não se encontra esse tipo de relações, apenas nos detalhes do filme.

```
texto = """
Mila Kunis going down on Natalie Portman IS modern cinema.
So strange that life goes on after finishing a film like Call Me By Your Name.
Do not ever, EVER, travel anywhere with Matt Damon
"""

extrair_entidades(texto)
```

	entidade	categoria	início	fim
0	Mila Kunis	PERSON	1	11
1	Natalie Portman	PERSON	26	41
2	Call Me By Your Name	ORG	117	137
3	EVER	ORG	152	156
4	Matt Damon\n	PERSON	179	190

	filme	resenha_original	nota_resenha	sentimento_nota	sentimento_confianca	sentimento
0	10 Things I Hate About You	the moral of the story is that all men are evi...	5.0	1	0.269418	Negativo
1	10 Things I Hate About You	kat stratford is the most relatable character ...	5.0	1	0.321497	Negativo
2	10 Things I Hate About You	me: i hate cliches	5.0	1	0.577521	Negativo
3	10 Things I Hate About You	funny how shakespeare's been real quiet since ...	5.0	5	0.485101	Positivo
4	10 Things I Hate About You	heath ledger: *dances down steps with giant le...	3.5	4	0.322166	Positivo
5	10 Things I Hate About You	I hate the way this film romanticizes the hard...	4.0	2	0.406459	Negativo
6	10 Things I Hate About You	dear men, what's stopping you from being like ...	5.0	5	0.325692	Positivo
7	10 Things I Hate About You	heath ledger with his hair tied up, covered in...	5.0	2	0.349031	Negativo
8	10 Things I Hate About You	this is the best high school film bc it includ...	4.0	5	0.781683	Positivo
9	10 Things I Hate About You	the scene where bianca finally realises boys a...	5.0	3	0.260125	Neutro



6) Sim. Técnicas de scraping auxiliaram para a criação da nossa base de dados utilizada, retornando as informações necessárias (nome do filme, ano de lançamento, produção do filme, dados sobre resenhas individuais dos usuários). Técnicas de embedding e classificação também foram úteis.